Configurando via Maven propriedades do projeto

UFGD - TAC I 03 - Joinvile Batista Junior

Configurando via Maven dependências

- repetir dependências do Spark com artifactId
 - spark-sql 2.11 spark-mllib 2.11 spark-graphx 2.11
 - spark-yarn_2.11 spark-network-shuffle_2.11
 - spark-streaming-flume 2.11

```
<dependency>
     <groupId>com.databricks</groupId>
     <artifactId>spark-csv_2.11</artifactId>
     <version>1.3.0</version>
</dependency>
```

UFGD - TAC I 03 - Joinvile Batista Junior

2

Configurando via Maven dependências

UFGD - TAC I 03 - Joinvile Batista Junior

3

Configurando via Maven

```
plugins
<build>
 <plugin>
      <groupId>org.apache.maven.plugins</groupId>
      <artifactId>maven-eclipse-plugin</artifactId>
      <version>2.9</version>
      <configuration>
        <downloadSources>true</downloadSources>
        <downloadJavadocs>false</downloadJavadocs>
      </configuration>
   </plugin>
   <plugin>
      <groupId>org.apache.maven.plugins</groupId>
      <artifactId>maven-compiler-plugin</artifactId>
      <version>3.5.1</version>
      <configuration>
        <source>${jdk.version}</source>
        <target>${jdk.version}</target>
      </configuration>
                   UFGD - TAC I 03 - Joinvile Batista Junior
   </plugin>
```

Configurando via Maven plugins

UFGD - TAC I 03 - Joinvile Batista Junior

5

Configurando via Maven plugins

UFGD - TAC I 03 - Joinvile Batista Junior

Configurando via Maven plugins

```
<executions>
    <execution>
        <id>make-assembly</id>
        <phase>package</phase>
        <goals>
            </goal>single</goal>
            </goals>
            </execution>
            </executions>
        </plugin>
        </build>
```

UFGD - TAC I 03 - Joinvile Batista Junior

7

Importações

java.io

Serializable

java.util

- HashMap
- Map

UFGD - TAC I 03 - Joinvile Batista Junior

Importações

org.apache.spark

- api.java.JavaRDD
 - ml
 - classification
 - MultilayerPerceptronClassificationModel
 - MultilayerPerceptronClassifier
 - evaluation.MulticlassClassificationEvaluator
- mllih
 - feature.StandardScalerModel
 - linalg
 - Vector
 - Vectors
 - stat
 - MultivariateStatisticalSummary
 - Statistics
 - util.MLUtils

UFGD - TAC I 03 - Joinvile Batista Junior

9

Importações

org.apache.spark.sql

- •
- api.java.UDF1
- types.DataTypes

scala

- Option
- Some
- Tuple2
- Tuple3

static org.apache.spark.sql.functions

- callUDF
- col

UFGD - TAC I 03 - Joinvile Batista Junior

Criando Classe Auxiliar : Par de Vetores

para armazenar rótulo survived e suas características normalizadas

```
public static class VectorPair implements Serializable {
    private double label;
    private Vector features;

public VectorPair(double label, Vector features) {
        this.label = label;
        this.features = features;
    }
    public VectorPair() {}
    public Vector getFeatures() { return this.features; }
    public void setFeatures(Vector features) { this.features = features; }
    public double getLabel() { return this.label; }
    public void setLabel(double label) { this.label = label; }
}
```

UFGD - TAC I 03 - Joinvile Batista Junior

11

Dados da Classe

```
private static SparkSession spark;
private static MultivariateStatisticalSummary summary = null;
private static double mean_fare_column;
private static double mean_age_column;
private static StandardScalerModel scaler;
private static Dataset<Row> trainingData;
private static Dataset<Row> validationData;
```

UFGD - TAC I 03 - Joinvile Batista Junior

Main

UFGD - TAC I 03 - Joinvile Batista Junior

13

Criando uma Sessão Spark

UFGD - TAC I 03 - Joinvile Batista Junior

Leitura dos Dados de Treinamento

UFGD - TAC I 03 - Joinvile Batista Junior

15

UDFs para Conversão para Valores Numéricos Portas de Embarque – Sexo

```
private static UDF1<String,Option<Integer>> normEmbarked=(String d) ->
    {
        if (null == d return Option.apply(null);
        else if (d.equals("S")) return Some.apply(0);
            else if (d.equals("C")) return Some.apply(1);
            else return Some.apply(2);
        }
}

private static UDF1<String, Option<Integer>> normSex = (String d) -> {
        if (null == d) return Option.apply(null);
        else if (d.equals("male")) return Some.apply(0);
        eles return Some.apply(1);
        };
}
```

UFGD - TAC I 03 - Joinvile Batista Junior

ETL dos Dados de Treinamento lendo dados de treinamento

```
private static Dataset<Row> doETL_TrainingData() {
    Dataset<Row> input_data = readTrainingData();
```

UFGD - TAC I 03 - Joinvile Batista Junior

17

ETL dos Dados de Treinamento

seleção das colunas relevantes - conversão das não numéricas

spark.sqlContext().udf().register

```
("normSex", normSex, DataTypes.IntegerType);
spark.sqlContext().udf().register
    ("normEmbarked", normEmbarked, DataTypes.IntegerType);

Dataset<Row> numeric_relevant_columns = input_data.select(
    col("Survived"),
    col("Fare"),
    callUDF("normSex", col("Sex")).alias("Sex"),
    col("Age"),
    col("Pclass"),
    col("Parch"),
    col("SibSp"),
    callUDF("normEmbarked",col("Embarked"))
        .alias("Embarked"));
numeric_relevant_columns.show();
```

UFGD - TAC I 03 - Joinvile Batista Junior

ETL dos Dados de Treinamento cálculos de valores médios de colunas com valores nulos

UFGD - TAC I 03 - Joinvile Batista Junior

19

ETL dos Dados de Treinamento UDFs para substituição de valores nulos por valores médios

```
UDF1<String, Option<Double>> normFare = (String d) -> {
    if (null == d) return Some.apply(mean_fare_column);
    else return Some.apply(Double.parseDouble(d));
};

UDF1<String, Option<Double>> normAge = (String d) -> {
    if (null == d) return Some.apply(mean_age_column);
    else return Some.apply(Double.parseDouble(d));
};
```

UFGD - TAC I 03 - Joinvile Batista Junior

ETL dos Dados de Treinamento substituindo valores nulos por valores médios spark.sqlContext().udf().register ("normFare", normFare, DataTypes.DoubleType); spark.sqlContext().udf() .register("normAge", normAge, DataTypes.DoubleType); Dataset<Row> without nulls numeric relevant columns = numeric relevant columns.select(col("Survived"), callUDF("normFare", col("Fare").cast("string")).alias("Fare"), col("Sex"), callUDF("normAge", col("Age").cast("string")).alias("Age"), col("Pclass"), col("Parch"), col("SibSp"), col("Embarked")); without nulls numeric relevant columns.show(); return without nulls numeric relevant columns; } UFGD - TAC I 03 - Joinvile Batista Junior 21

Funções Auxiliares para Normalizar Colunas

```
private static Tuple3<Double, Double, Double> flattenPclass
      (double value) {
   Tuple3<Double, Double, Double> result;
  if (value == 1) result = new Tuple3<>(1d, 0d, 0d);
  else if (value == 2) result = new Tuple3<>(0d, 1d, 0d);
  else result =new Tuple3<>(0d, 0d, 1d);
  return result;
}
private static Tuple3<Double, Double, Double> flattenEmbarked
      (double value) {
   Tuple3<Double, Double, Double> result;
  if (value == 0) result = new Tuple3<>(1d, 0d, 0d);
   else if (value == 1) result = new Tuple3<>(0d, 1d, 0d);
   else result = new Tuple3<>(0d, 0d, 1d);
  return result;
}
                     UFGD - TAC I 03 - Joinvile Batista Junior
                                                                       22
```

Funções Auxiliares para Normalizar Colunas

```
private static Tuple2<Double, Double> flattenSex(double value) {
   Tuple2<Double, Double> result;
   if (value == 0) result = new Tuple2<>(1d, 0d);
   else result = new Tuple2<>(0d, 1d);
   return result;
}
```

UFGD - TAC I 03 - Joinvile Batista Junior

23

Normalizando Colunas

UFGD - TAC I 03 - Joinvile Batista Junior

Normalizando Dados de Treinamento calculando desvio padrão e média

Vector standard deviation

= Vectors.dense(Math.sqrt(summary.variance().apply(0)),

Math.sqrt(summary.variance().apply(1)));

scaler = new StandardScalerModel(standard_deviation, mean);

UFGD - TAC I 03 - Joinvile Batista Junior

25

Normalizando Dados de Treinamento

codificadores para valores numéricos

Encoder<Integer> integerEncoder = Encoders.INT();

Encoder<Double> doubleEncoder = Encoders.DOUBLE();

Encoders.BINARY();

Encoder<Vector> vectorEncoder = Encoders.kryo(Vector.class);

Encoders.tuple(integerEncoder, vectorEncoder);

Encoders.tuple(doubleEncoder, vectorEncoder);

UFGD - TAC I 03 - Joinvile Batista Junior

Normalizando Dados de Treinamento

par de vetores para rótulo e características normalizadas

```
JavaRDD
JavaRDD

= trainingDataSet.toJavaRDD().map(row -> {

VectorPair vectorPair = new VectorPair();

vectorPair.setLabel(new Double(row.<Integer>getAs("Survived")));

vectorPair.setFeatures(getScaledVector(

row.<Double>getAs("Fare"),

row.<Integer>getAs("Age"),

row.<Integer>getAs("Pclass"),

row.<Integer>getAs("Sex"),

row.isNullAt(7) ? 0d : row.<Integer>getAs("Embarked"), scaler));

return vectorPair;

});
```

UFGD - TAC I 03 - Joinvile Batista Junior

27

Normalizando Dados de Treinamento convertendo RDD do Vetor para Vetor Mlib

UFGD - TAC I 03 - Joinvile Batista Junior

Treinando a Rede

convertendo Vetor Mlib para Vetor ML para utilizar MLP do Spark dividindo dados entre treinamento e validação

UFGD - TAC I 03 - Joinvile Batista Junior

29

Treinando a Rede configurando a rede e gerando o modelo da rede

}

UFGD - TAC I 03 - Joinvile Batista Junior

Avaliando a Rede gerando os avaliadores

Avaliando a Rede

UFGD - TAC I 03 - Joinvile Batista Junior

calculando e visualizando as métricas de avaliação

```
double accuracy = evaluator1.evaluate(predictions);
double precision = evaluator2.evaluate(predictions);
double recall = evaluator3.evaluate(predictions);
double f1 = evaluator4.evaluate(predictions);

System.out.println("Accuracy = " + accuracy);
System.out.println("Precision = " + precision);
System.out.println("Recall = " + recall);
System.out.println("F1 = " + f1);
System.out.println("Test Error = " + (1 - accuracy));
```

}

UFGD - TAC I 03 - Joinvile Batista Junior

32

Gerando Dados de Teste

tratando colunas não numéricas - lendo dados de teste

UFGD - TAC I 03 - Joinvile Batista Junior

33

Gerando Dados de Teste selecionando colunas relevantes

```
return testData.select(
    col("PassengerId"),
    col("Fare"),
    callUDF("normSex", col("Sex")).alias("Sex"),
    col("Age"),
    col("Pclass"),
    col("Parch"),
    col("SibSp"),
    callUDF("normEmbarked", col("Embarked")).alias("Embarked"));
}
```

UFGD - TAC I 03 - Joinvile Batista Junior

Testando a Rede

gerando os dados de teste substituindo valores nulos (usando Map em vez de UDF)

UFGD - TAC I 03 - Joinvile Batista Junior

35

Testando a Rede

criando pares de vetores com rótulo e características normalizadas

```
JavaRDD<VectorPair> testRDD = testData2.javaRDD().map(row -> {
    VectorPair vectorPair = new VectorPair();
    vectorPair.setLabel(row.<Integer>getAs("PassengerId"));
    vectorPair.setFeatures(getScaledVector(
        row.<Double>getAs("Fare"),
        row.<Double>getAs("Age"),
        row.<Integer>getAs("Pclass"),
        row.<Integer>getAs("Sex"),
        row.<Integer>getAs("Embarked"),
        scaler));
    return vectorPair;
});
```

UFGD - TAC I 03 - Joinvile Batista Junior

Testando a Rede

criando DataFrame convertendo vetores Mlib para ML gerando a predição

```
Dataset<Row> scaledTestData
= spark.createDataFrame(testRDD, VectorPair.class);

Dataset<Row> finalTestData
= MLUtils.convertVectorColumnsToML(scaledTestData)
.toDF("features", "PassengerId");
trainingData.show();
finalTestData.show();

Dataset<Row> resultDF = model.transform(finalTestData)
.select("PassengerId", "prediction");
resultDF.show();
return resultDF;

UFGD-TAC I 03 - Joinvile Batista Junior
```

}